51 | 并行算法:如何利用并行处理提高算法的执行效率?

time.geekbang.org/column/article/78795

王争 2019-01-23



秌

00:00

09:55

讲述:修阳 大小:9.10M

时间复杂度是衡量算法执行效率的一种标准。但是,时间复杂度并不能跟性能划等号。在真实的软件开发中,即便在不降低时间复杂度的情况下,也可以通过一些优化手段,提升代码的执行效率。毕竟,对于实际的软件开发来说,即便是像 10%、20% 这样微小的性能提升,也是非常可观的。

算法的目的就是为了提高代码执行的效率。那**当算法无法再继续优化的情况下,我们该如何来进一步提高执行效率呢**?我们今天就讲一种非常简单但又非常好用的优化方法,那就是并行计算。 今天,我就通过几个例子,给你展示一下,**如何借助并行计算的处理思想对算法进行改造?**

并行排序

假设我们要给大小为 8GB 的数据进行排序,并且,我们机器的内存可以一次性容纳这么多数据。对于排序来说,最常用的就是时间复杂度为 O(nlogn) 的三种排序算法,归并排序、快速排序、堆排序。从理论上讲,这个排序问题,已经很难再从算法层面优化了。而利用并行的处理思想,我们可以很轻松地将这个给 8GB 数据排序问题的执行效率提高很多倍。具体的实现思路有下面两种。

第一种是对归并排序并行化处理。我们可以将这 8GB 的数据划分成 16 个小的数据集合,每个集合包含 500MB 的数据。我们用 16 个线程,并行地对这 16 个 500MB 的数据集合进行排序。这 16 个小集合分别排序完成之后,我们再将这 16 个有序集合合并。

第二种是对快速排序并行化处理。我们通过扫描一遍数据,找到数据所处的范围区间。我们把这个区间从小到大划分成 16 个小区间。我们将 8GB 的数据划分到对应的区间中。针对这 16 个小区间的数据,我们启动 16 个线程,并行地进行排序。等到 16 个线程都执行结束之后,得到的数据就是有序数据了。

对比这两种处理思路,它们利用的都是分治的思想,对数据进行分片,然后并行处理。它们的区别在于,第一种处理思路是,先随意地对数据分片,排序之后再合并。第二种处理思路是,先对数据按照大小划分区间,然后再排序,排完序就不需要再处理了。这个跟归并和快排的区别如出一辙。

这里我还要多说几句,如果要排序的数据规模不是 8GB,而是 1TB,那问题的重点就不是算法的执行效率了,而是数据的读取效率。因为 1TB 的数据肯定是存在硬盘中,无法一次性读取到内存中,这样在排序的过程中,就会有频繁地磁盘数据的读取和写入。如何减少磁盘的 IO 操作,减少磁盘数据读取和写入的总量,就变成了优化的重点。不过这个不是我们这节要讨论的重点,你可以自己思考下。

并行查找

我们知道,散列表是一种非常适合快速查找的数据结构。

如果我们是给动态数据构建索引,在数据不断加入的时候,散列表的装载因子就会越来越大。为了保证散列表性能不下降,我们就需要对散列表进行动态扩容。对如此大的散列表进行动态扩容,一方面比较耗时,另一方面比较消耗内存。比如,我们给一个 2GB 大小的散列表进行扩容,扩展到原来的 1.5 倍,也就是 3GB 大小。这个时候,实际存储在散列表中的数据只有不到 2GB,所以内存的利用率只有 60%,有 1GB 的内存是空闲的。

实际上,我们可以将数据随机分割成 k 份 (比如 16 份) ,每份中的数据只有原来的 1/k ,然后我们针对这 k 个小数据集合分别构建散列表。这样,散列表的维护成本就变低了。当某个小散列表的装载因子过大的时候,我们可以单独对这个散列表进行扩容,而其他散列表不需要进行扩容。

还是刚才那个例子,假设现在有 2GB 的数据,我们放到 16 个散列表中,每个散列表中的数据大约是 150MB。当某个散列表需要扩容的时候,我们只需要额外增加 150*0.5=75MB 的内存(假设还是扩容到原来的 1.5 倍)。不管从扩容的执行效率还是内存的利用率上,这种多个小散列表的处理方法,都要比大散列表高效。

当我们要查找某个数据的时候,我们只需要通过 16 个线程,并行地在这 16 个散列表中查找数据。这样的查找性能,比起一个大散列表的做法,也并不会下降,反倒有可能提高。

当往散列表中添加数据的时候,我们可以选择将这个新数据放入装载因子最小的那个散列表中,这样也有助于减少散列冲突。

并行字符串匹配

我们前面学过,在文本中查找某个关键词这样一个功能,可以通过字符串匹配算法来实现。我们之前学过的字符串匹配算法有 KMP、BM、RK、BF 等。当在一个不是很长的文本中查找关键词的时候,这些字符串匹配算法中的任何一个,都可以表现得非常高效。但是,如果我们处理的是超级大的文本,那处理的时间可能就会变得很长,那有没有办法加快匹配速度呢?

我们可以把大的文本,分割成 k 个小文本。假设 k 是 16,我们就启动 16 个线程,并行地在这 16 个小文本中查找关键词,这样整个查找的性能就提高了 16 倍。16 倍效率的提升,从理论的角度来说并不多。但是,对于真实的软件开发来说,这显然是一个非常可观的优化。

不过,这里还有一个细节要处理,那就是原本包含在大文本中的关键词,被一分为二,分割到两个小文本中,这就会导致尽管大文本中包含这个关键词,但在这 16 个小文本中查找不到它。实际上,这个问题也不难解决,我们只需要针对这种特殊情况,做一些特殊处理就可以了。

我们假设关键词的长度是 m。我们在每个小文本的结尾和开始各取 m 个字符串。前一个小文本的末尾 m 个字符和后一个小文本的开头 m 个字符,组成一个长度是 2m 的字符串。我们再拿关键词,在这个长度为 2m 的字符串中再重新查找一遍,就可以补上刚才的漏洞了。

并行搜索

前面我们学习过好几种搜索算法,它们分别是广度优先搜索、深度优先搜索、Dijkstra 最短路径算法、A* 启发式搜索算法。对于广度优先搜索算法,我们也可以将其改造成并行算法。

广度优先搜索是一种逐层搜索的搜索策略。基于当前这一层顶点,我们可以启动多个线程,并行地搜索下一层的顶点。在代码实现方面,原来广度优先搜索的代码实现,是通过一个队列来记录已经遍历到但还没有扩展的顶点。现在,经过改造之后的并行广度优先搜索算法,我们需要利用两个队列来完成扩展顶点的工作。

假设这两个队列分别是队列 A 和队列 B。多线程并行处理队列 A 中的顶点,并将扩展得到的顶点存储在队列 B 中。等队列 A 中的顶点都扩展完成之后,队列 A 被清空,我们再并行地扩展队列 B 中的顶点,并将扩展出来的顶点存储在队列 A。这样两个队列循环使用,就可以实现并行广度优先搜索算法。

总结引申

上一节,我们通过实际软件开发中的"索引"这一技术点,回顾了之前学过的一些支持动态数据集合的数据结构。今天,我们又通过"并行算法"这个话题,回顾了之前学过的一些算法。

今天的内容比较简单,没有太复杂的知识点。我通过一些例子,比如并行排序、查找、搜索、字符串匹配,给你展示了并行处理的实现思路,也就是对数据进行分片,对没有依赖关系的任务,并行地执行。

并行计算是一个工程上的实现思路,尽管跟算法关系不大,但是,在实际的软件开发中,它确实 可以非常巧妙地提高程序的运行效率,是一种非常好用的性能优化手段。

特别是,当要处理的数据规模达到一定程度之后,我们无法通过继续优化算法,来提高执行效率的时候,我们就需要在实现的思路上做文章,利用更多的硬件资源,来加快执行的效率。所以,在很多超大规模数据处理中,并行处理的思想,应用非常广泛,比如 MapReduce 实际上就是一种并行计算框架。

课后思考

假设我们有 n 个任务,为了提高执行的效率,我们希望能并行执行任务,但是各个任务之间又有一定的依赖关系,如何根据依赖关系找出可以并行执行的任务?

欢迎留言和我分享,也欢迎点击"请朋友读",把今天的内容分享给你的好友,和他一起讨论、学习。



© 版权归极客邦科技所有,未经许可不得传播售卖。 页面已增加防盗追踪,如有侵权极客邦将依法追究其法律责任。



涛强

Command + Enter 发表

0/2000字

提交留言

精选留言(24)



失火的夏天

思考题用一个有向图来存储任务之间的依赖关系,然后用拓扑排序的思想来执行任务,每次都找到入度为0的,放在队列里,启动线程池开始执行,队列里的任务并行执行完毕,再次调用拓扑排序找到入度为0的人,放入队列,直到所以任务跑完

2019-01-23

祸

頻 56



Jerry银银

一看到依赖,就想到了拓扑。

这种感觉好是还是不好呢?

2019-01-23

祸

頻 10



hua168

老师,我就问一个题外问题: 大专学历,想直接自学考本科或研究生,自考学历IT类公司承认的吗? 很多都要求全日制本科~~

2019-01-23

祸

姐8



◎您的好友William◎

使用拓扑关系来构建图安排计算顺序,这个spark, tensorflow都是这么安排的,效率比最开始的MapReduce还要高很多。

2019-02-08

祸

姐4



茴香根

思考题讲的够直白了,n个任务有互相依赖。那么并行处理的方法就要采用流水线的思想了。创建n个线程,每个线程完成一个任务。每个线程在它的上游线程结束输出结果后启动,完成之后把结果传递给下游任务线程继续流程。整个工作场景像工厂里面的流水线一样,每一个线程都努力地重复着某一阶段的任务,提高整体资源利用率。

2019-01-23

祸

姐4



DFighting

现在才明白,其实最底层的数据结构是<addr,value>,按照存储介质是否连续、是否显示制

定key又可以分为数组、链表和hash,其中数组可以认为是一种<index,arr[index]>,链表是<p,*p>,然后在这基础之上衍生出了一维的线性表、栈、队列,散列表,二维的树(平衡二叉树、红黑树、跳表),三维的图,还有就是各种数据结构灵活组合的数据结构,这里的跳表可以算是组合类型的,但是它的使用范围很多,所以划到了二维中。这些是存储然后是算法:排序、分治、贪心、回溯、动态规划

第一次真正感觉到了数据结构和算法的关联,好神奇的感觉。至少现在觉得那些难记的算法、数据结构没那么困难了,多思考、实践总会能够像写代码般应用到实际中。

2019-08-13

祸

姐3



Geek 46cdcd

请问老师,广度优先搜索中用两个队列是为了解决多线程的并发问题吗?

作者回复: 是的

2019-05-09

祸1

姐1



牧民牛仔

既然有依赖关系,我条件反射想到拓扑排序算法,根据依赖关系把任务分组,各组任务按 照依赖关系排序。没有依赖关系的任务组可以并行执行,有依赖关系的任务组内则按依赖 关系有序的执行。

2019-01-24

祸

頻1



Smallfly

并行搜索只用一个队列不可以么?

作者回复: 也可以的。不过就有可能导致没法找到最短路径了。

2019-01-23

祸

姐 1



子嘉

思考题是:拓扑排序么。。

2019-01-23

祸

妲1



纯洁的憎恶

并行与分治的区别是什么?前者偏工程,后者偏算法么?还是前者在并发环境中,后者在 单核串行环境中?

作者回复: 并行是一种工程思路。分治是一种算法思想。感觉差不多哈;) 你理解就好,不要太纠结;)

2019-01-23

猫

姐1



mrlay

我觉得能够并行执行多少个任务,是取决于这些任务之间的依赖关系;采用拓扑只是为了确认任务的先后执行。 最坏的情况下还是会变成串行的。

2019-07-21

祸

狽



Geek 54edc1

利用两个队列A和B,多线程并行处理A队列中的顶点(入度为0),并将入度为0的扩展顶点(扩展顶点的入度减1)入队B,A队列中顶点都处理完,队列A清空,再并行处理B队列中顶点,并将入度为0的扩展顶点(扩展顶点的入度减1)入队A,如此两个队列循环使用

2019-06-01

祸

狽



朱东旭

老师,并行搜索在你的描述中是先操作队列A,再操作队列B,这是有先后顺序,这意味着是串行的不是并行呀。

作者回复: 是并行处理完队列a,然后并行处理队列b这个样子的。并不是a、b的处理是并行的。

2019-05-10

祸

娯



xuery

想到的第一个思路就是前面所讲的拓扑排序,任务之间的关系用有向图表示,如果是采用khan遍历,则每次找到入度为0的,同时多线程执行,等他们执行完(java可以通过CountDownLatch来模拟实现),然后同理找到入度为0的任务,继续同理执行,直到全部执行完

2019-04-09

祸

娯



yaya

将各任务通过依赖关系做成图,然后进行并行计算

2019-02-20

祸

娯



睡痴儿②

使用的是拓扑排序,刚开始还以为太简单。不可能是这样

2019-01-27

祸

狽



オオ

打卡,继续学习。

2019-01-25

祸

娯



小苏饼

spark, oozie的有向无环图

2019-01-24

祸

娯



绿茶

计算机不一定都是n核的,怎么实现性能提升n倍呢

作者回复: 即便是n核也不一定提高n倍, 毕竟还共享内存呢:)

我这里本就是粗略的表示:)

2019-01-23

祸

娯

收起评论祇